

Trabalho Prático Aprendizado de Máquina - PNS 2019

Vitor Totaro Fialho
PUC Minas Lourdes
Minas Gerais, Brasil
vitor.t.fialho@gmail.com

Abstract

O objetivo é utilizar as diversas variáveis socioeconômicas, demográficas e de estilo de vida da PNS 2019 para construir um modelo de classificação capaz de identificar os principais fatores preditivos que distinguem o grupo de indivíduos diagnosticados com diabetes do grupo de controle (indivíduos sem nenhuma doença crônica, considerados saudáveis).

ACM Reference Format:

Vitor Totaro Fialho. 2026. Trabalho Prático Aprendizado de Máquina - PNS 2019. In . ACM, New York, NY, USA, 8 pages. <https://doi.org/10.1145/nnnnnnn.nnnnnnn>

1 Introdução

O diabetes mellitus consolidou-se como um grande desafio de saúde pública, exigindo abordagens preditivas e preventivas cada vez mais precisas. Segundo a 11ª edição do Atlas da Federação Internacional de Diabetes (IDF, 2025) [8], aproximadamente 589 milhões de adultos vivem com a doença globalmente, sendo esta a causa de 3,4 milhões de mortes apenas no ano de 2024. No cenário nacional, a presença da doença é evidente: o Brasil ocupa a 6ª posição mundial em número absoluto de casos, com 16,6 milhões de adultos afetados. De forma preocupante, estima-se que 32% desses indivíduos brasileiros sequer possuam diagnóstico. É frente a esse cenário crítico, aliado ao alto impacto socioeconômico da doença, que a aplicação de técnicas de mineração de dados sobre bases como a Pesquisa Nacional de Saúde (PNS 2019), revela sua importância.

Ao investigar essa base para identificar os principais fatores associados à incidência da doença, especialmente em indivíduos com até 60 anos, torna-se possível extrair padrões que auxiliam no rastreamento precoce e na formulação de estratégias de intervenção em saúde. O problema central abordado neste estudo é a predição da incidência do diabetes tipo 2 e a identificação de seus fatores preditivos utilizando técnicas de mineração de dados sobre os microdados da Pesquisa Nacional de Saúde (PNS) de 2019. Diversos trabalhos na literatura exploram esse tema sob diferentes escopos. Paula et al. (2022), por exemplo, utilizaram algoritmos de classificação como Random Forest para prever multimorbidades, incluindo o diabetes, na base do ELSA-Brasil. Pesquisas internacionais, como as relacionadas a base BRFSS nos Estados Unidos, também aplicam

Regressão Logística e Redes Neurais para triagem preditiva, evidenciando a eficácia do aprendizado de máquina em grandes inquéritos de saúde.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta os Trabalhos Relacionados ; a Seção 3 detalha a Metodologia, subdividida em Materiais, Métodos e Métricas de avaliação; a Seção 4 descreve a Modelagem e Análise de Resultados ; e, por fim, a Seção 5 traz as Avaliações de resultados e a Seção 6 e 7 trazem Conclusões, Explicabilidade, Limitações e propostas para Trabalhos Futuros.

1.1 Descrição do trabalho

Segundo a Sociedade Brasileira de Diabetes, "O diabetes mellitus tipo 2 é o tipo mais comum. Está frequentemente associado à obesidade e ao envelhecimento. [...]" [15]. Observando-se isso, propõe-se o foco da pesquisa a seguir em: Análise e Identificação de Fatores Determinantes Associados à Prevalência de Diabetes Mellitus tipo 2 na População Brasileira.

A análise foca em uma subpopulação que se estende dos 35 aos 60 anos para os saudáveis e, no caso dos diabéticos, quem recebeu o diagnóstico nessa faixa de idade. A definição desse recorte etário para a pesquisa deu-se após exploração da idade de diagnóstico que pode ser visualizado através de um gráfico de frequência acumulada (figura 1). Isso com base em Técnicas de Mineração de Dados aplicadas aos microdados da Pesquisa Nacional de Saúde (PNS) 2019.




Figure 1: Gráfico de frequência acumulada simples mostrando a idade de diagnóstico da doença

2 Trabalhos Relacionados

A aplicação de técnicas de aprendizado de máquina tem se mostrado uma ferramenta valiosa na análise e predição de agravos à saúde.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
Conference'17, Washington, DC, USA

© 2026 Copyright held by the owner/author(s). Publication rights licensed to ACM.
ACM ISBN 978-x-xxxx-xxxx-x/YYYY/MM
<https://doi.org/10.1145/nnnnnnn.nnnnnnn>

Nesse contexto, Paula et al. (2022) investigaram a predição de multimorbidades crônicas utilizando dados da coorte ELSA-Brasil. Por meio da aplicação do algoritmo Random Forest, os autores demonstraram que fatores sociodemográficos e antropométricos, com destaque para o Índice de Massa Corporal (IMC), despontam como os preditores mais consistentes.

Focando especificamente no rastreamento do diabetes mellitus, diversas pesquisas internacionais têm validado a eficácia de diferentes modelos preditivos aplicados a grandes inquéritos populacionais. Yu et al. (2010), por exemplo, utilizaram Support Vector Machines (SVM) no banco de dados americano NHANES, alcançando alta precisão na detecção precoce de pacientes ainda não diagnosticados com a doença. Seguindo uma linha investigativa semelhante para o diabetes tipo 2, Xie et al. (2019) empregaram modelos de Árvore de Decisão e Regressão Logística na base estadunidense BRFSS. O estudo revelou novos indicadores comportamentais como fatores de risco secundários, complementando o painel de variáveis clínicas tradicionais. Ainda no escopo da detecção precoce, mas utilizando bancos de dados clínicos estruturados, Awoniran et al. (2022) compararam a eficácia dos algoritmos K-Nearest Neighbors (KNN) e Naive Bayes, concluindo que o KNN apresenta resultados altamente competitivos na classificação de anomalias glicêmicas.

Além do rigor na escolha algorítmica, a estruturação do problema de pesquisa é um fator determinante para o sucesso dos modelos. Zárate et al. (2023) abordaram a dificuldade inerente ao entendimento do domínio em projetos de ciência de dados na área da saúde e propuseram a metodologia CAPTO. Os autores evidenciaram que a realização de uma modelagem conceitual prévia melhora drasticamente a assertividade das predições. Trazendo essas abordagens metodológicas para o cenário nacional, Aquino (2021) investigou o diabetes tipo 2 no Brasil utilizando os microdados da edição de 2013 da Pesquisa Nacional de Saúde (PNS). Através do emprego de algoritmos de classificação supervisionada, o estudo confirmou que os determinantes sociais exercem uma influência significativa no diagnóstico da doença, estabelecendo uma base sólida para a continuidade das investigações preditivas com as edições mais recentes e atualizadas desse inquérito demográfico.

Diferença para a literatura: Diferentemente de muitos trabalhos da literatura, que frequentemente ignoram o desbalanceamento inerente às doenças crônicas ou focam apenas na métrica de acurácia global, este estudo utiliza a base mais recente da PNS (2019) com foco rigoroso na otimização da métrica Recall. Além disso, inova ao testar empiricamente as abordagens de reamostragem extrema (Undersampling, Oversampling) e híbrida (SMOTEENN), acopladas a uma otimização Bayesiana de hiperparâmetros.

3 Metodologia

3.1 Materiais

O banco de dados utilizado é derivado dos microdados da Pesquisa Nacional de Saúde (PNS) 2019, elaborada pelo Instituto Brasileiro de Geografia e Estatística (IBGE) [17]. Trata-se de um inquérito de base populacional com amostra probabilística e representatividade nacional. Originalmente composta por 279.382 registros, a base abrange aspectos socioeconômicos, demográficos e medições antropométricas, sendo fundamental para capturar os determinantes de saúde da população brasileira.

3.2 Métodos

O pipeline de processamento e descoberta de conhecimento foi estruturado nas seguintes etapas:

Etapas 1 e 2 - Escopo e Modelagem Conceitual: Aplicou-se o método CAPTO para entendimento do domínio do problema. Construiu-se um mapa conceitual sólido para guiar a mineração, garantindo que os padrões a serem extraídos refletissem a epidemiologia real. **Etapas 3 - Seleção Conceitual de Atributos:** Com base no mapa, cerca de 30 atributos pertinentes (como demografia, hábitos de saúde e alimentação) foram criteriosamente selecionados para compor o escopo preditivo. A seguir, apresenta-se o mapa conceitual construído acerca da doença de acordo com o modelo CAPTO [9]. Vale ressaltar que o modelo conceitual utilizado é o mesmo apresentado no método CAPTO [9] (descrição do mapa conceitual - tabela 1); [Link de acesso](#)



Figure 2: Mapa conceitual

Etapas 4 - Tratamento de Dados Ausentes e Vazios: Valores vazios decorrentes de saltos lógicos do questionário (ex: perguntas não aplicáveis por faixa etária ou gênero) foram tratados de forma sistêmica, majoritariamente substituídos por '0'. Para lacunas legítimas, aplicou-se a técnica de imputação iterativa não-paramétrica MissForest. **Etapas 5 - Análise e Tratamento de Outliers:** Utilizou-se a técnica de capping, limitando os valores extremos aos percentis 1 e 99 das distribuições, o que reduziu o impacto de ruídos biológicos impossíveis sem causar perda de registros. **Etapas 6 - Preparação, Combinação e Discretização:** A base foi enriquecida através da engenharia de features. Criou-se as variáveis consolidadas `Peso_Final` e `Altura_Final_cm` pela média das medições aferidas e calculou-se o IMC contínuo dos indivíduos. **Etapas 7 - Seleção Técnica de Atributos (Entropia/Gini):** A seleção de features foi retroalimentada pelos próprios estimadores baseados em árvore (Decision Tree e Random Forest). Esses algoritmos particionaram os dados avaliando o Ganho de Informação baseado na Entropia e na redução da impureza de Gini, estabelecendo uma ordem quantitativa de importância das variáveis. **Etapas 8 - Balanceamento de Dados:** Enfrentou-se o desequilíbrio estrutural da base testando três abordagens no conjunto de treinamento: Undersampling (redução aleatória dos saudáveis), Oversampling sintético via SMOTE e o método Híbrido SMOTEENN. **Etapas 9 e 10 - Treinamento, Parametrização e Teste:** A base foi subdividida mantendo a estratificação espacial em 70% para treinamento e 30% como conjunto trancado para teste. Os modelos selecionados (KNN, Decision Tree

e Random Forest) foram treinados com uma otimização Bayesiana (BayesSearchCV) validada internamente por Cross-Validation de 5 partições (folds), utilizando o F1-Score como métrica guia.

3.3 Métricas de Avaliação

Em um problema de diagnóstico de saúde, a acurácia por si só não é uma métrica suficiente. Deu-se foco especial às seguintes métricas para a classe positiva (Diabetes):

- **Precisão (Precision):** De todas as previsões "Diabetes" feitas pelo modelo, quantas estavam corretas? (Mede a confiabilidade do diagnóstico positivo, minimizando Falsos Positivos). Pode ser definida matematicamente pela equação:

$$Precision = \frac{VP}{VP + FP} \quad (1)$$

Sendo VP o número de Verdadeiros Positivos e FP o número de Falsos Positivos.

- **Recall (Sensibilidade):** De todas as pessoas que realmente tinham diabetes, quantas o modelo conseguiu identificar? (Mede a capacidade de encontrar a doença, minimizando Falsos Negativos). Sua equação é dada por:

$$Recall = \frac{VP}{VP + FN} \quad (2)$$

Sendo FN o número de Falsos Negativos.

- **F1-Score:** A média harmônica entre Precisão e Recall, fornecendo uma pontuação única que equilibra ambas as métricas. Sabendo que a fórmula geral da média harmônica (H) para duas variáveis x e y é $H = \frac{2}{\frac{1}{x} + \frac{1}{y}}$, a equação final do F1-Score é descrita como:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3)$$

Após a seleção de atributos, tem-se as variáveis exibidas na tabela 1.

4 Modelagem e Otimização de Hiperparâmetros

[Link de acesso ao código](#)

Nesta etapa, procedeu-se à aplicação e avaliação de algoritmos de Machine Learning para o problema de classificação (identificação de diabetes). Os dados utilizados foram os conjuntos de treino e teste gerados na etapa anterior. Foram selecionados três algoritmos distintos para comparação: K-Nearest Neighbors (KNN), Árvore de Decisão (Decision Tree) e Random Forest.

4.1 Estratégia de Otimização: BayesSearchCV

Para encontrar a melhor combinação de hiperparâmetros para cada modelo, foi empregada a Otimização Bayesiana através da biblioteca scikit-optimize (skopt) e sua função BayesSearchCV. Conforme demonstrado por Snoek et al. [16], esta abordagem trata a busca de hiperparâmetros como um problema de otimização, onde o algoritmo "aprende" com as execuções anteriores para escolher de forma mais inteligente e computacionalmente eficiente as próximas combinações a serem testadas.

A métrica alvo para a otimização foi o 'f1-score', uma vez que é uma métrica robusta para lidar com a avaliação em conjuntos desbalanceados (como o nosso conjunto de teste). Foi utilizada uma validação cruzada de 5 folds (cv=5) e um total de 15 iterações de

busca (n_iter=15) para cada modelo, cada modelo sendo utilizado em todas as abordagens (Desbalanceada, OverSampling e Híbrido).

4.2 Espaços de Busca Definidos

Os intervalos e parâmetros testados para cada modelo foram estruturados conforme a Tabela 2.

Table 2: Espaços de Busca de Hiperparâmetros por Algoritmo

Algoritmo	Hiperparâmetro	Espaço de Busca / Valores
KNN	n_neighbors	Inteiro: 3 a 30
	weights	'uniform', 'distance'
	metric	'euclidean', 'manhattan'
Decision Tree	criterion	'gini', 'entropy'
	max_depth	[3, 5, 10, 15]
	min_samples_split	[2, 5, 10, 20]
	min_samples_leaf	[1, 2, 5, 10]
Random Forest	n_estimators	[20, 30, 40, 60, 70, 90, 120, 150]
	criterion	'gini', 'entropy'
	max_depth	[3, 5, 10, 15]
	min_samples_split	[2, 5, 10, 20]
	min_samples_leaf	[1, 2, 5, 10]

5 Resultados e discussões

Após a conclusão do BayesSearchCV, os melhores estimadores (.best_estimator_) de cada algoritmo e abordagem foram utilizados para fazer previsões no conjunto de teste (teste.csv), que o modelo nunca havia visto.

A Tabela 3 apresenta um exemplo dos hiperparâmetros ótimos encontrados para a abordagem base (desbalanceada). Cabe ressaltar que cada abordagem de balanceamento encontrou seu próprio conjunto ideal de hiperparâmetros.

Table 3: Exemplo de Hiperparâmetros Encontrados (Base Desbalanceada)

Hiperparâmetro	KNN	Decision Tree	Random Forest
n_neighbors	3	N/A	N/A
metric	manhattan	N/A	N/A
weights	uniform	N/A	N/A
criterion	N/A	Gini	Gini
max_depth	N/A	15	10
min_samples_split	N/A	2	10
min_samples_leaf	N/A	10	10
n_estimators	N/A	N/A	60
max_features	N/A	N/A	none

5.1 Métricas encontradas

A seguir estão as tabelas que evidenciam as métricas de cada modelo consolidadas por abordagem de balanceamento:

Table 1: Dicionário Completo de Variáveis Seleccionadas

Variável	Descrição da variável	Código/valor	Descrição da resposta
SEXO	Sexo	1 2	Homem Mulher
FEIJAO	Em quantos dias da semana o(a) Sr(a) costuma comer feijão?	1 a 7 0	Dias Nunca ou menos de uma vez por semana
VERDURA_LEGUME	Em quantos dias da semana, o(a) Sr(a) costuma comer pelo menos um tipo de verdura ou legume (sem contar batata, mandioca, cará ou inhame) como alface, tomate, couve, cenoura, chuchu, berinjela, abobrinha?	1 a 7 0	Dias Nunca ou menos de uma vez por semana
FREQ_VERDURA_LEGUME	Em geral, o(a) Sr(a) costuma comer esse tipo de verdura ou legume:	1 2 3 0	Uma vez por dia (no almoço ou no jantar). Duas vezes por dia (no almoço e no jantar). Três vezes ou mais por dia. Não consome
CARNE_VERMELHA	Em quantos dias da semana o(a) Sr(a) costuma comer carne vermelha (boi, porco, cabrito, bode, ovelha etc.)?	1 a 7 0	Dias Nunca ou menos de uma vez por semana.
FRANGO_GALINHA	Em quantos dias da semana o(a) Sr(a) costuma comer frango/galinha?	1 a 7 0	Dias Nunca ou menos de uma vez por semana.
PEIXE	Em quantos dias da semana o(a) Sr(a) costuma comer peixe?	1 a 7 0	Dias Nunca ou menos de uma vez por semana.
SUCO_INDUSTRIALIZADO	Em quantos dias da semana o(a) Sr(a) costuma tomar suco de caixinha/lata ou refresco em pó?	1 a 7 0	Dias Nunca ou menos de uma vez por semana.
TIPO_SUCO_INDUSTIALIZADO	Que tipo de suco de caixinha/lata ou refresco em pó o(a) Sr(a) costuma tomar?	1 2 3 0	Diet/Light/Zero Normal Ambos. Não consome
SUCO_NATURAL	Em quantos dias da semana o(a) Sr(a) costuma tomar suco de fruta natural (incluída a polpa de fruta congelada)?	1 a 7 0	Dias Nunca ou menos de uma vez por semana.
FRUTA_SEMANA	Em quantos dias da semana o(a) Sr(a) costuma comer frutas?	1 a 7 0	Dias Nunca ou menos de uma vez por semana.
FREQ_FRUTA_DIA	Em geral, quantas vezes por dia o(a) Sr(a) come frutas?	1 2 3 0	Uma vez por dia Duas vezes por dia Três vezes ou mais por dia. Não consome
REFRIGERANTE_SEMANA	Em quantos dias da semana o(a) Sr(a) costuma tomar refrigerante?	1 a 7 0	Dias Nunca ou menos de uma vez por semana.
TIPO_REFRIGERANTE	Que tipo de refrigerante o(a) Sr(a) costuma tomar?	1 2 3 0	Diet/Light/Zero Normal Ambos Não consome
LEITE_SEMANA	Em quantos dias da semana o(a) Sr(a) costuma tomar leite? (de origem animal: vaca, cabra, búfala etc.)	1 a 7 0	Dias Nunca ou menos de uma vez por semana.
TIPO_LEITE	Que tipo de leite o(a) Sr(a) costuma tomar?	1 2 3 0	Desnatado ou semidesnatado. Integral Os dois tipos Não consome
DOCES_SEMANA	Em quantos dias da semana costuma comer alimentos doces como biscoito/bolacha recheado, chocolate, gelatina, balas e outros?	1 a 7 0	Dias Nunca ou menos de uma vez por semana
SUBSTITUIR_REFEICAO_DOCE_SEMANA	Em quantos dias da semana o(a) Sr(a) costuma substituir a refeição do almoço por lanches rápidos como sanduíches, salgados, pizza, cachorro quente, etc?	1 a 7 0	Dias Nunca ou menos de uma vez por semana
Peso_Final	Peso - Média entre 1ª e 2ª pesagem (em kg)(3 inteiros e 1 casa decimal)	20 a 200	Quilogramas
Altura_Final_cm	Altura - Média entre 1ª e 2ª medição (em cm) (3 inteiros e 1 casa decimal)	110 a 210	Centímetros
IMC	IMC calculado utilizando peso e altura (2 inteiros e duas casas decimais)	0 a 50	IMC (decimal)
FAIXA_RENDA_SM	Faixa de renda(em salários mínimos da época)	1 2 3 4 5	Até 1 SM Mais de 1 até 2 SM Mais de 2 até 5 SM Mais de 5 até 10 SM Mais de 10 SM
NIVEL_CONSUMO_ALCOOL	Nível do consumo de álcool	0 1 2 3 4	Não consome Consumo Ocasional Leve Consumo Semanal Leve Consumo Ocasional Pesado (Binge) Consumo Semanal Pesado
NIVEL_ATIVIDADE_FISICA	Nível da prática de atividade física	0 1 2	Sedentário Ativo (Nível Baixo) Ativo (Nível Alto)

Table 4: Performance dos Modelos - Abordagem: Desbalanceado (Base)

Algoritmo	Classe	Precision	Recall	F1-Score
KNN (Acc: 0.7764)	0 (Não Diab.)	0.8332	0.8965	0.8637
	1 (Diabetes)	0.4538	0.3240	0.3781
Decision Tree (Acc: 0.7773)	0 (Não Diab.)	0.8315	0.9008	0.8647
	1 (Diabetes)	0.4550	0.3121	0.3702
Random Forest (Acc: 0.7966)	0 (Não Diab.)	0.8292	0.9352	0.8790
	1 (Diabetes)	0.5291	0.2742	0.3612

Table 5: Performance dos Modelos - Abordagem: Undersampling

Algoritmo	Classe	Precision	Recall	F1-Score
KNN (Acc: 0.6652)	0 (Não Diab.)	0.8943	0.6536	0.7553
	1 (Diabetes)	0.3520	0.7090	0.4705
Decision Tree (Acc: 0.5810)	0 (Não Diab.)	0.9004	0.5282	0.6658
	1 (Diabetes)	0.3049	0.7798	0.4384
Random Forest (Acc: 0.7067)	0 (Não Diab.)	0.8982	0.7093	0.7926
	1 (Diabetes)	0.3889	0.6971	0.4992

Table 6: Performance dos Modelos - Abordagem: Oversampling (SMOTE)

Algoritmo	Classe	Precision	Recall	F1-Score
KNN (Acc: 0.6980)	0 (Não Diab.)	0.8508	0.7493	0.7968
	1 (Diabetes)	0.3483	0.5049	0.4123
Decision Tree (Acc: 0.7279)	0 (Não Diab.)	0.8430	0.8057	0.8239
	1 (Diabetes)	0.3726	0.4348	0.4013
Random Forest (Acc: 0.7929)	0 (Não Diab.)	0.8534	0.8909	0.8718
	1 (Diabetes)	0.5076	0.4236	0.4618

Table 7: Performance dos Modelos - Abordagem: Híbrido (SMOTEENN)


Algoritmo	Classe	Precision	Recall	F1-Score
KNN (Acc: 0.5451)	0 (Não Diab.)	0.8857	0.4873	0.6286
	1 (Diabetes)	0.2831	0.7630	0.4130
Decision Tree (Acc: 0.6507)	0 (Não Diab.)	0.8814	0.6447	0.7447
	1 (Diabetes)	0.3346	0.6732	0.4470
Random Forest (Acc: 0.7092)	0 (Não Diab.)	0.8934	0.7177	0.7960
	1 (Diabetes)	0.3890	0.6774	0.4942

5.2 Análise dos Relatórios de Classificação


Os resultados consolidados no conjunto de teste revelaram que as técnicas de balanceamento foram essenciais para tornar os modelos úteis para o nosso propósito clínico.

- **Random Forest (com Undersampling):** Foi o modelo que apresentou o melhor equilíbrio geral (F1-Score: 0.4992). Com o balanceamento via Undersampling, ele atingiu um Recall de aproximadamente 0.70, o que significa que ele identificou 70% dos casos reais de diabetes, mantendo uma Acurácia razoável de 70%. Ele superou a versão desbalanceada, que só identificava 27% dos doentes.

- **Decision Tree (com Undersampling):** Destacou-se por ter o maior Recall entre os modelos baseados em árvore (0.78). Este modelo foi extremamente agressivo na detecção da doença, errando menos falsos negativos. No entanto, sua Precisão caiu drasticamente (0.30), indicando que para encontrar esses doentes, ele classificou muitos saudáveis incorretamente, resultando em um F1-Score inferior ao do Random Forest.
- **KNN (com SMOTEENN):** Apresentou uma sensibilidade muito alta (Recall de 0.76), superando a maioria dos outros cenários. Contudo, sofreu do mesmo problema da árvore de decisão: a baixa precisão (0.28) derrubou a Acurácia global para cerca de 54%. Isso mostra que o KNN, neste dataset da PNS, tende a gerar muito "ruído" quando forçamos o aprendizado da classe minoritária.

**Figure 3: Gráfico comparativo das métricas de cada algoritmo por abordagem**

5.3 Análise Visual

**Figure 4: Comparação de recall por algoritmo e abordagem**

A análise das matrizes de confusão geradas no notebook corroboram os números acima:

As matrizes dos modelos com técnicas de balanceamento (Undersampling e SMOTEENN) mostram claramente uma migração de erros: diminuimos os Falsos Negativos (o que é ótimo para medicina) ao custo de aumentar os Falsos Positivos.

A matriz do Baseline (Desbalanceado) visualmente parece "limpa" na classe majoritária (quase não erra saudáveis), mas é desastrosa na classe alvo, falhando em detectar a grande maioria dos diabéticos.

6 Conclusão da Etapa de Modelagem

Considerando o objetivo do projeto de mineração de dados da PNS, onde a prioridade é a detecção de uma condição crônica (Diabetes):

- (1) **O Vencedor Técnico:** Random Forest com Undersampling é a escolha mais robusta. Ele oferece o melhor compromisso, detectando cerca de 70% dos casos (Recall 0.70) sem destruir completamente a precisão do diagnóstico, mantendo o maior F1-Score do experimento (0.499).
- (2) **Para Triagem Agressiva:** Se o objetivo fosse puramente uma triagem inicial onde "nenhum doente pode ficar para trás", a Decision Tree com Undersampling (Recall 0.78) poderia ser considerada, mas o custo operacional de verificar tantos falsos positivos seria alto.
- (3) **Descarte do Baseline:** Os modelos sem balanceamento (Baseline), apesar de terem acurácia de quase 80%, são inúteis para o nosso problema, pois funcionam praticamente como classificadores da classe majoritária (Saudáveis), ignorando a doença.

Portanto, o modelo selecionado para a fase de interpretação de variáveis e deploy será o Random Forest treinado com dados balanceados via Undersampling. A próxima etapa focará em entender quais variáveis do questionário da PNS (como IMC, Idade, Hipertensão) foram decisivas para as previsões deste modelo.

Como protocolo para um eventual ambiente de produção (deploy), o modelo final escolhido (Random Forest com Undersampling) deve ser retreinado utilizando a totalidade das amostras disponíveis (treino + teste). Esse processo garante que o modelo em produção absorva todo o conhecimento distributivo capturado nas matrizes de confusão do experimento, mitigando os falsos negativos e maximizando sua capacidade de generalização clínica.

7 Ordem de Importância de Atributos e Explicabilidade

Após a seleção dos modelos, avançamos da análise de performance pura para a interpretabilidade clínica. Entender quais fatores o algoritmo considera decisivos é fundamental para validar a confiança médica na ferramenta. Abaixo, exploramos como o Random Forest (nosso modelo mais robusto) e a Árvore de Decisão (nosso modelo mais sensível) tomam suas decisões.

7.1 Fatores de Risco no Random Forest

O gráfico abaixo ilustra as variáveis (features) que o modelo Random Forest (treinado com Undersampling) considerou mais relevantes para distinguir entre um paciente saudável e um diabético. O eixo X representa o grau de importância (baseado na redução de impureza de Gini acumulada).




Figure 5: Top 10 Fatores de Risco encontrados pelo Random Forest com Undersampling

Análise: Observe que o modelo não "chuta" aleatoriamente; ele prioriza variáveis que fazem sentido biológico e epidemiológico.

- **Atributos no Topo:** Variáveis que aparecem no topo do gráfico são vistas como as mais importantes para a classificação. O modelo aprendeu que alterações nestes indicadores aumentam drasticamente a probabilidade de diabetes.
- **Cauda Longa:** Variáveis com menor importância ainda contribuem para o ajuste fino da probabilidade, ajudando a desempatar casos limítrofes (borderline).

7.2 Convergência com a Literatura Fisiopatológica

A hierarquia de importância de atributos definida pelo algoritmo (Figura 5) demonstra uma forte convergência com a literatura médica estabelecida sobre a fisiopatologia do Diabetes Mellitus Tipo 2 (DM2). O fato do modelo ter aprendido esses padrões de forma autônoma valida sua aplicabilidade clínica.

- **Macrodeterminantes (Atributos no Topo):** O destaque isolado do Índice de Massa Corporal (IMC) e do Peso reflete o consenso da Sociedade Brasileira de Diabetes [15]. Fisiologicamente, o excesso de tecido adiposo é o gatilho primário para a resistência à insulina, mediada pela liberação de citocinas inflamatórias (lipotoxicidade). Da mesma forma, o consumo de álcool, posicionado logo abaixo do IMC, afeta diretamente a gliconeogênese hepática, sendo um preditor autônomo agressivo reconhecido na literatura. O modelo identifica, corretamente, que alterações nestes parâmetros elevam a probabilidade base da doença de forma abrupta.
- **Moduladores Metabólicos (Cauda Longa):** As variáveis de menor importância, que formam a cauda longa do gráfico (consumo de refrigerantes, doces, carne vermelha e tipos de leite), representam o ambiente nutricional crônico do indivíduo. Conforme apontado por estudos de padrões alimentares [1], o consumo de açúcares adicionados e gorduras saturadas gera picos repetitivos de glicemia e inflamação sistêmica de baixo grau.

Corroborando com os achados de Xie et al. (2019) [12], o Random Forest utilizou essas variáveis comportamentais exatamente

como fatores de risco secundários. Isoladamente, esses hábitos alimentares não determinam a doença de imediato no modelo, mas atuam como "ajustes finos" (*fine-tuning*) matemáticos essenciais para desempatar a classificação de pacientes limítrofes, capturando a progressão silenciosa da síndrome metabólica.

7.3 As Regras de Decisão e Cobertura (Árvore de Decisão)

Enquanto o Random Forest nos dá a importância geral dos atributos, a Árvore de Decisão treinada com a abordagem híbrida SMOTEENN nos fornece um fluxograma explícito de triagem. Em vez de visualizar a árvore completa — que se torna complexa devido à profundidade —, a extração das regras primárias (nó raiz e primeiras ramificações) nos permite entender o perfil de decisão lógico do modelo sobre as 17.734 amostras de treinamento.

Cabe ressaltar que os valores limiares de decisão refletem a padronização prévia dos dados (onde valores negativos indicam medidas abaixo da média da amostra, e valores positivos indicam medidas acima da média). A seguir, detalhamos a estrutura inicial de triagem do algoritmo:

- **A Regra Raiz (Principal Divisor):** A primeira decisão tomada pelo modelo (o topo da árvore) baseia-se exclusivamente no consumo de refrigerante com açúcar (TIPO_REFRI-GERANTE_2 $\leq$ 1.235). Essa única variável foi capaz de separar toda a base de treinamento em duas grandes macrorregiões de risco lógico, indicando seu forte poder discriminatório.
- **Perfil de Risco Primário (Ramo à Esquerda):** Quando a condição do nó raiz é verdadeira (menor consumo/frequência de refrigerante normal), o modelo desce para avaliar o nível de consumo de álcool (NIVEL_CONSUMO_ALCOOL $\leq$ 0.738). Se verdadeiro, ele avalia a faixa de renda (FAIXA_RENDA_SM $\leq$ -1.352). Esse fluxo lógico agrupou a maior parte da população, resultando em um nó com **10.287 amostras** (equivalente a mais de 58% do conjunto) classificado majoritariamente como positivo para Diabetes ("Sim").
- **A Influência do IMC (Ramo à Direita):** Por outro lado, se a condição raiz é falsa (maior consumo de refrigerante normal), o algoritmo imediatamente passa a avaliar o Índice de Massa Corporal (IMC $\leq$ 0.423). Para as **5.573 amostras** que caíram nesse lado da árvore, o modelo traçou dois caminhos:
 - **Caminho de Controle:** IMC abaixo da média combinados a cortes da variável SEXO direcionaram grande parte das amostras (3.694) para a classificação de pacientes saudáveis ("Não").
 - **Caminho de Alerta:** IMC acima do limiar de corte ($>$ 0.423) associado a níveis específicos de consumo alcoólico isolou um grupo de **1.879 amostras** com forte tendência para classificação da doença ("Sim").

7.4 Validação Clínica

A coerência entre os atributos mais importantes do Random Forest e as regras de corte da Árvore de Decisão sugere que os modelos conseguiram capturar padrões reais da fisiopatologia do Diabetes, e não apenas ruídos estatísticos da base de dados. Isso aumenta a

segurança para um eventual deploy da solução como ferramenta de apoio à decisão médica.

- (1) **Impacto do Balanceamento de Dados:** Ficou evidente que a aplicação de algoritmos em dados brutos (desbalanceados) tende a enviesar o resultado para a classe majoritária (saudáveis). Embora a acurácia fosse alta (79%), a capacidade de detectar doentes (Recall) era inaceitável para triagem médica (30%). As técnicas de reamostragem (Undersampling, SMOTE e SMOTEENN) foram cruciais para corrigir essa distorção, elevando a sensibilidade dos modelos para patamares acima de 70%.
- (2) **Melhor Modelo:** O algoritmo Random Forest, combinado com a técnica de Undersampling, demonstrou ser a solução mais equilibrada e robusta. Ao atingir um F1-Score de aproximadamente 0.50 e um Recall de 0.70, ele ofereceu o melhor compromisso entre identificar corretamente os pacientes diabéticos e minimizar o número de falsos positivos, superando o KNN (que gerou muitos alarmes falsos) e a Árvore de Decisão (que apresentou maior instabilidade).
- (3) **Relevância Clínica:** A análise de importância de atributos (feature importance) validou o modelo sob a ótica médica. Variáveis como IMC (Índice de Massa Corporal) e Consumo de Álcool foram identificadas como os preditores mais fortes. Isso confirma que o modelo não apenas encontrou padrões estatísticos, mas capturou a fisiopatologia real da doença, alinhando-se à literatura médica existente sobre fatores de risco para Diabetes Tipo 2.

8 Conclusão, Limitações e Trabalhos Futuros

O presente estudo alcançou seu objetivo principal de desenvolver e avaliar modelos de Machine Learning capazes de identificar fatores determinantes associados à prevalência de Diabetes Mellitus na população brasileira, utilizando dados da PNS 2019. A análise focou no desafio crítico de lidar com classes desbalanceadas em um cenário de saúde pública.

8.1 Limitações do Trabalho

A natureza transversal do inquérito (PNS 2019) impõe limitações empíricas, pois não é possível estabelecer uma relação de causalidade temporal estrita entre a exposição aos fatores de risco e o desenvolvimento posterior do diabetes. Além disso, as variáveis comportamentais, como consumo de álcool e alimentação, são autorreferidas, estando suscetíveis a vieses de memória e de aprovação social.

8.2 Trabalhos Futuros

Como próximos passos para a evolução contínua da pesquisa, sugere-se:

Deploy em Dashboard Médico: Implementar o modelo analítico no back-end de uma ferramenta de Business Intelligence (como Power BI) ou aplicação web interativa, simulando um painel financeiro e clínico para uso por gestores de unidades de saúde. **Algoritmos Genéticos para Seleção de Atributos:** Explorar algoritmos heurísticos para encontrar a combinação ótima e mínima de respostas do questionário que garantam a predição correta. **Análise**

de Causalidade: Aprofundar o estudo das variáveis socioeconômicas visando discernir quais atuam como causas diretas e quais são apenas variáveis de confusão.

References

- [1] C. Whiteley, F. Benton, L. Matwiejczyk, e N. Luscombe-Marsh. 2023. Determining Dietary Patterns to Recommend for Type 2 Diabetes: An Umbrella Review. *Nutrients*, 15(4), 861.
- [2] Y. Liu, et al. 2025. Effects of 12 nutritional interventions on type 2 diabetes: a systematic review with network meta-analysis of randomized trials. *Nutrition & Metabolism*, 22(94).
- [3] R. R. Mir, N. U. Haq, K. Ishaq, N. Safie, e A. B. Dogar. 2025. Impact of machine learning on dietary and exercise behaviors in type 2 diabetes self-management: a systematic literature review. *PeerJ Computer Science*, 11:e2568.
- [4] A. D. Sarma e M. Devi. 2025. Artificial intelligence in diabetes management: transformative potential, challenges, and opportunities in healthcare. *Hormones (Athens)*.
- [5] E. Fix e J. L. Hodges. 1951. Discriminatory Analysis. Nonparametric Discrimination: Consistency Properties. *USAF School of Aviation Medicine. Project No. 21-49-004*, Report No. 4.
- [6] L. Breiman, J. Friedman, R. Olshen, e C. Stone. 1984. *Classification and Regression Trees*. Chapman & Hall/CRC.
- [7] L. Breiman. 2001. Random Forests. *Machine Learning*, 45(1), 5-32.
- [8] International Diabetes Federation. 2025. *IDF Diabetes Atlas*. Bruxelas, Bélgica: International Diabetes Federation. Acesso em: 21 fev. 2026. <https://diabetesatlas.org/>.
- [9] L. E. Zárata, B. Petrocchi, C. D. Maia, C. Felix, e M. P. S. Gomes. 2023. CAPTO - A Method for Understanding Problem Domains for Data Science Projects. *Concilium*, 23(15), 922-941.
- [10] D. P. Paula e O. B. Aguiar. 2022. Comparing machine learning algorithms for multimorbidity prediction: An example from the Elsa-Brasil study. *PLOS One*, 17(10), e0275619. <https://doi.org/10.1371/journal.pone.0275619>
- [11] W. Yu, T. Liu, R. Valdez, M. Gwinn, e M. J. Khoury. 2010. Application of support vector machine modeling for prediction of common diseases: the case of diabetes and pre-diabetes. *BMC Medical Informatics and Decision Making*, 10(1), 16. <https://doi.org/10.1186/1472-6947-10-16>
- [12] Z. Xie, O. Nikolayeva, J. Luo, e D. Li. 2019. Building risk prediction models for type 2 diabetes using machine learning techniques. *Preventing Chronic Disease*, 16, E130. <https://doi.org/10.5888/pcd16.190109>
- [13] O. M. Awoniran, M. O. Oyelami, R. N. Ikono, R. F. Famutimi, e T. I. Famutimi. 2022. A machine learning technique for detection of diabetes mellitus. Em: *International Conference on Prognostic Evaluation, Prediction and Regimen of Diseases (IETA)*. <https://www.ieta.org/download/file/fid/125622>
- [14] L. S. Aquino. 2021. *Fatores de risco para diabetes tipo 2 no Brasil: uma análise Machine Learning*. Dissertação de Mestrado. Programa de Pós-Graduação em Economia, Universidade Católica de Brasília, Brasília. <https://bdtd.ucb.br:8443/jspui/handle/tede/2787>
- [15] Sociedade Brasileira de Diabetes. 2021. Classificação e Diagnóstico do Diabetes Mellitus. *Diretriz Oficial da Sociedade Brasileira de Diabetes*. Retrieved March, 2026 from: <https://diretriz.diabetes.org.br/classificacao-do-diabetes/#ftoc-introducao>.
- [16] J. Snoek, H. Larochelle, e R. P. Adams. 2012. Practical Bayesian optimization of machine learning algorithms. Em *Advances in Neural Information Processing Systems (NIPS 2012)*, Vol. 25. Curran Associates, Inc., 2951-2959.
- [17] Instituto Brasileiro de Geografia e Estatística (IBGE). 2020. *Pesquisa Nacional de Saúde 2019: Microdados*. Acesso em: 31 mar. 2026. <https://www.ibge.gov.br/estatisticas/sociais/saude/9160-pesquisa-nacional-de-saude.html>